Erasing Digital Sticky Notes: A SoftwareO Developer's Adventure in PII Data Removal



Daniel Aniszkiewicz
1st June 2023
AWS Community Day Warsaw







Senior Software Engineer - obecnie Algoteque AWS Community Builder (Serverless) Q4 2021 Co-organizer AWS User Group Wrocławo

Czym są wrażliwe dane (PII)?



Case



- firma ubezpieczeniowa.
- sprzedaje polisy ubezpieczeniowe.
- system CRM gdzie są wszystkie dane klientów.

Architektura



Monolit (Ruby on Rails) z bazą Postgres na AWS.



Stare czasy







Problem



Do każdej polisy sprzedawca może dodać ogólnodostępne notatki dla pracowników całej firmy.

Ktoś zauważył, że w notatkach są dane kart kredytowych i nie tylko.

Przykład notatki do polisy



"Please charge this client for the renewal of the insurance policy. His credit card number is xxx, pin xxx, cvc xxx. His SSN is xxx and his full residential address is xxx."







- 500 tysięcy notatek, potencjalnie każda może mieć w sobie PII.
- notatki nie mają określonej struktury, może tam być cokolwiek.
- notatek nie można było edytować i usuwać.



Cel

Przychodzi managerka i mówi:

Znajdź wszystkie notatki które zawierają PII i zredaguj je!

Context is the king!



Co mogę zrobić?

Jakie mam opcje?

- Ręcznie je sprawdzić?
- Regexy?
- SaaSy?
- Jakieś libki?
- Samodzielnie ogarnąć AI/ML?
- Zmienić pracę?







Funkcjonalności



Social media posts, emails, web pages, documents, phone transcripts and medical records



Amazon Comprehend

Automatically extract key phrases, entities, sentiment, language, syntax, topics and document classifications



Entities



Sentiment



Key Phrases





Language



Topics

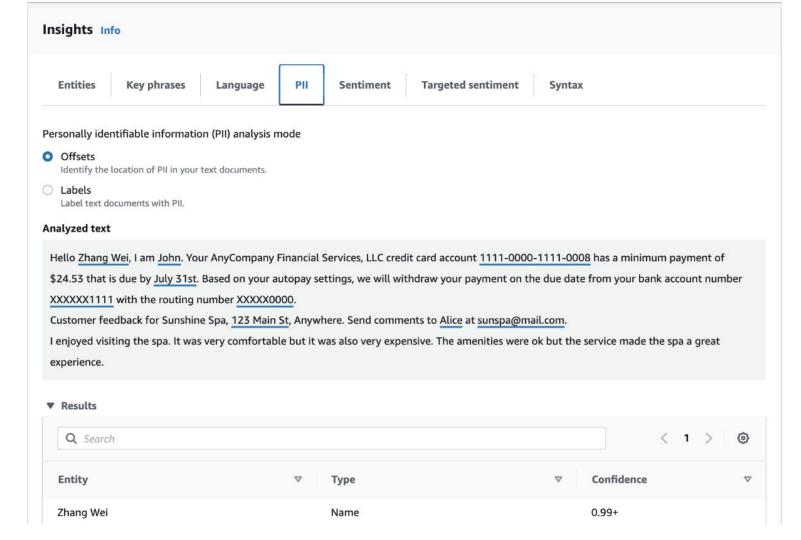


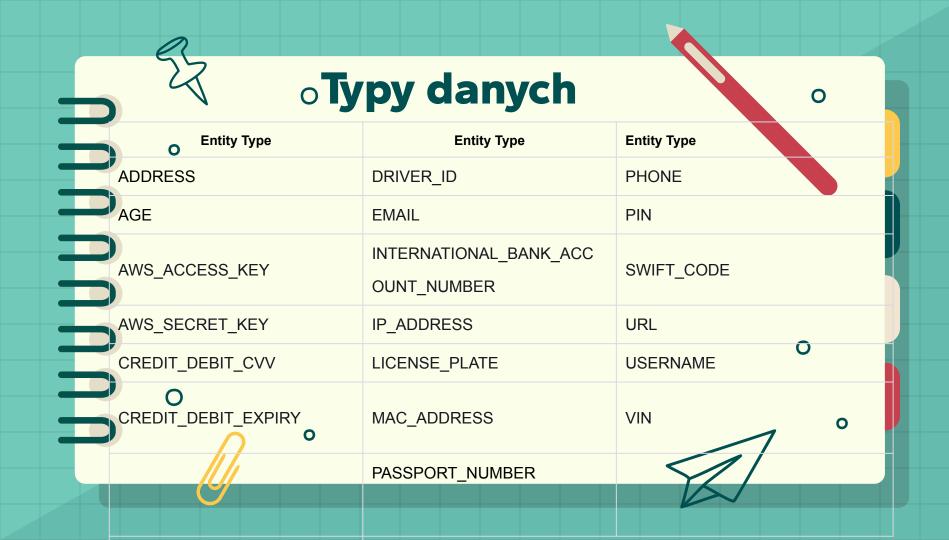
Document Classifications

Extracts data, topics, and document classifications with confidence scores











Amazon Comprehend

Rodzaje detekcji

synchroniczna

asynchroniczna

- odpowiedź w czasie rzeczywistym
 - limit znaków 5,000 na jeden request
 - redagowanie tekstu we własnym zakresie
- background job
- Input i Output w S3
- 1MB tekstu na jeden request
- Możliwość automatycznego redagowania tekstu

Detekcja synchroniczna

ContainsPiiEntities

nnnnf

DetectsPiiEntities



0

```
import { Comprehend } from "aws-sdk";
. . .
const text = "My name is Daniel, my email
is example@example.com my pin number is 1234";
const params: PiiEntitiesRequest = {
    LanguageCode: "en",
    Text: text,
  };
const detectPiiResponse = await comprehend
  .detectPiiEntities(params)
  .promise();
const containsPiiResponse = await comprehend
  .containsPiiEntities(params)
  .promise();
```

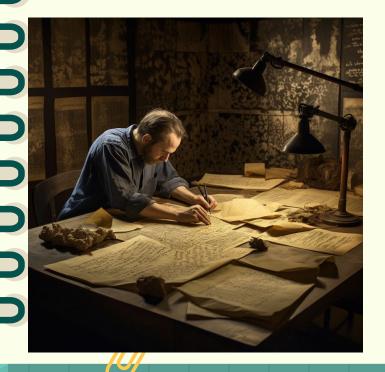
```
"fullResponseContains": {
   "Labels": [
       "Name": "PIN",
       "Score": 1
     },
       "Name": "EMAIL",
       "Score": 1
      },
       "Name": "NAME",
       "Score": 1
```

Różnica?

Offsety

```
"DetectPiiResponse": {
    "Entities": [
        "Score": 0.9999493360519409,
       "Type": "NAME",
        "BeginOffset": 11,
        "EndOffset": 17
       "Score": 0.9999399185180664,
        "Type": "EMAIL",
        "BeginOffset": 31,
        "EndOffset": 50
        "Score": 0.9998846054077148,
        "Type": "PIN",
        "BeginOffset": 68,
        "EndOffset": 72
```





"In-house" odejmując od siebie offsety, prosta operacja na stringu.



Własne typy PII



Czyli co, jeśli Comprehend nie wspiera naszych typów PII

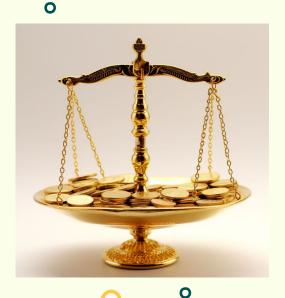
Entity Lists

- działa jak słownik, gdzie przekazujemy wszystkie możliwe wyrażenia.
- prosty i szybki, przez to nie do końca dokładny.
- mogą być bardzo precyzyjne, jeśli frazy, których szukamy, są dość. unikalne i nie zmieniają się często.

Annotations

- bardziej elastyczny.
- uczy wzorców.
- wymaga znacznie więcej pracy.
- wymaga wielu zaawansowanych przykładów.





Zgadnijcie jaka cena za sprawdzenie 500 tysięcy notatek?

Detects PII
Entities
250\$





Jak liczyć koszty

1 unit = 100 znaków

Price Per Unit

Feature	Up to 10M units	From 10M - 50M units	From 50M - 100M units	Over 100M units
Detect PII	\$0.0001	\$0.00005	\$0.000025	\$0.000005
Contains PII	\$0.000002	\$0.000001	\$0.000005	\$0.000001







Przykład

10,000 notatek, każda zawiera 450 znaków.

4,5 miliona znaków = 45000 units (1 unit = 100 znaków)

Contains PII Entity:

Cena za jeden unit = 0.000002\$

45000 units * (0.000002) = **0.09\$**

Detects PII Entity:

Cena za jeden unit = 0.0001\$

45000 units * (0.0001) = **4.5\$** • •



Demo App



Link: bitly.ws/FWGJ

Repo:

https://github.com/Pigius/pii-service





Demo App

Submit

My name is Dante

Creation date:

Detected PII entities:

 Dante is a NAME PII data type with a score of 0.9999828338623047

Redacted content:

My name is *****

Message length: 16

My pin number to credit card is as follow: 1234

Creation date:

Detected PII entities:

 1234 is a PIN PII data type with a score of 0.983748197555542

Redacted content:

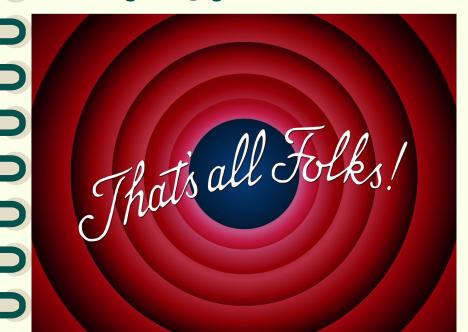
My pin number to credit card is as follow: ****

Message length: 47

Evaluation survey



Dziękuję!



Keep in touch:

Linkedin: Daniel Aniszkiewicz